

Junho 03, 2026

Análise de Dados ENEM 2023

TIME 4:

Anna Clara Olbi - 24015392

Larissa Furlan Ferreira - 24021876

Luca Francesco Filippi - 25022556

Maria Gabriella Xavier Puccinelli- 24002540

Fontes de Dados Oficiais

- Os arquivos usados:

Microdados ENEM 2023

Base bruta massiva (~3.9M de registros) contendo:

- Perfil sociodemográfico completo
- Questionário socioeconômico (Renda familiar)
- Status de presença e notas detalhadas

Itens prova 2023

Matriz técnica que permitiu a integração do Parâmetro B (dificuldade média) para cada área do conhecimento:

- Ciências da Natureza e Humanas
- Linguagens e Matemática

Base Principal

A base principal consiste nos **Microdados do ENEM 2023**, obtidos através do portal de Dados Abertos do INEP.

Por que esta base?

- Relevância: É o maior exame educacional do país.
- Volume: Milhões de registros que desafiam a otimização de código.
- Riqueza: Permite cruzar performance acadêmica com variáveis sociais profundas.

3.9M+
Registros Iniciais

Caracterização dos Dados

Antes do tratamento, a base apresentava uma estrutura complexa e volumosa:

Estrutura Geral

- Linhas: 3.933.955 registros.
- Colunas: +70 variáveis (originais).
- Encoding: Latin-1 (ISO-8859-1).

Principais Variáveis

- Perfil: Sexo, Raça, Idade.
- Contexto: Tipo de Escola, Renda (Q006).
- Notas: CN, CH, LC, MT e Redação.
- Localização: UF e Município.

Junho 03, 2026

Preparação dos Dados

Redução

Dimensionalidade

Filtro de 18 variáveis essenciais, mais 4 via merge (Itens Prova), selecionadas por relevância estatística e foco nos objetivos analíticos.

CORREÇÃO DE ACENTO

Uso de encode/decode cirúrgico na coluna de municípios para sanar erros de exportação do INEP.

Limpeza

Remoção de candidatos faltosos/eliminados e tratamento de nulos na Redação (substituição por zero em casos anulados).

DICIONÁRIOS

Mapeamento de códigos brutos para categorias legíveis: Faixas de Renda (Q006), Cor/Raça e Tipos de Escola.

Integração

Execução de Merge para injetar a dificuldade média da prova no perfil de cada candidato (Colunas DIF_MT, DIF_CN, etc).

Novas Features

Cálculo da Média Geral e criação das faixas de Desempenho (Baixo, Médio e Alto).

Integração dos dados

Bases Integradas

- Microdados ENEM 2023 (enem_tratado.csv)
- Itens da Prova ENEM 2023 (ITENS_PROVA_2023.csv)

Processo realizado

- Leitura das duas bases utilizando Python e Pandas.
- Cálculo da dificuldade média das questões através do parâmetro B (TRI).
- Integração das informações de dificuldade da prova ao perfil de cada participante.
- Criação de novas colunas:
 - DIF_MT
 - DIF_CN
 - DIF_CH
 - DIF_LC

Resultado

- Base consolidada contendo dados socioeconômicos, desempenho acadêmico e dificuldade média das provas.
- Maior capacidade para análises estatísticas e comparações.

Benefícios da integração

- ✓ Base única consolidada
- ✓ Dados enriquecidos
- ✓ Novas métricas analíticas
- ✓ Maior poder de análise

Construção dos Dashboards

Objetivo

Permitir análises dinâmicas e identificar fatores que influenciam o desempenho dos participantes.

Dashboard 1 — Visão Geral

- Indicadores principais do exame (KPIs).
 - Média geral dos candidatos.
 - Ranking dos estados.
 - Comparação por idade e tipo de escola.
 - Mapa de desempenho por UF.
-

Dashboard 2 — Exploração Interativa

- Filtros por:
 - Sexo
 - Cor/Raça
 - Idioma
 - Administração Escolar
 - Matriz de Correlação entre disciplinas.
 - Histogramas de distribuição das notas.
 - Boxplots por faixa de renda.
-

Resultados e Insights

Insight 1

Diferença entre escolas públicas e privadas

- Escolas privadas:
 - Média $\approx$ 616 pontos
- Escolas públicas:
 - Média $\approx$ 516 pontos

→ **Diferença superior a 100 pontos.**

Insight 2

Renda influencia diretamente o desempenho

- Quanto maior a renda familiar,
- Maior a média obtida no ENEM.

→ **Relação positiva observada em todas as faixas analisadas.**

Insight 3

Estados do Sul e Sudeste lideram o ranking

- Minas Gerais: 565,14
- São Paulo: 564,92

→ **Melhores médias nacionais.**

Insight 4

- Alunos com bom desempenho em Matemática tendem a apresentar melhores resultados em Ciências da Natureza.

→ **Matemática e Ciências da Natureza possuem forte correlação**



Conclusão

- O projeto permitiu transformar milhões de registros brutos em informações relevantes.
- A preparação e integração dos dados foram fundamentais para garantir análises confiáveis.
- Os dashboards facilitaram a visualização dos resultados e a identificação de padrões.
- Os dados evidenciam a influência de fatores socioeconômicos e educacionais no desempenho dos candidatos.

"Os dados mostram que o desempenho no ENEM vai além do conhecimento acadêmico, refletindo também as condições sociais e educacionais dos participantes."

Junho 03, 2026

Obrigada!

Alguma duvida?
